





GPU programming foundations and performance optimization

Mario Morales Hernández (mmorales@unizar.es)

March18 2025

Outline

- Introduction
- Basic concepts in GPU computing
 - Understanding a loop
 - The GPU memory
 - CUDA example
- Performance optimization strategies
- Vectorization
- Memory access optimization
- Thread management and load balancing
- Computation optimization and best practices

What is GPU computing?

Definition

GPU computing refers to the use of a **Graphics Processing Unit (GPU)** to perform computation in applications traditionally handled by the Central Processing Unit (CPU). GPUs excel at processing **many tasks simultaneously**, making them ideal for complex computations and data-intensive tasks.

2 Evolution

Originally designed for rendering graphics in video games, GPUs have evolved to become highly efficient parallel processors, capable of a wide range of computational tasks beyond graphics rendering

3 Key Concept

Parallelism - **GPUs contain thousands of cores** designed for performing multiple calculations simultaneously, providing a significant speedup for compatible tasks.

CPU vs GPU: key differences

1 Architecture

CPUs consist of a few cores optimized for sequential serial processing, while GPUs have thousands of smaller, more efficient cores designed for parallel processing.

2 Use Cases

CPUs are versatile and excel at general-purpose tasks and single-threaded operations. GPUs are specialized for tasks that can be parallelized, such as simulations, data analysis, and machine learning.

3 Performance

For tasks suited to their architecture, GPUs can significantly outperform CPUs in terms of computation speed and efficiency.

CPU vs GPU: key differences


CPU

Optimized to reduce latency

Serial work

Few threads with high frequency

Large amount of memory but slow



GPU

Optimized for throughput

Paralell work

Many threads

"Smaller" memory capacity but faster

CPU + GPU applications: general principles

Offload parallel work to GPU

Parallel tasks (e.g., matrix multiplications, image processing) should be offloaded to the GPU for efficient execution.

Yeep sensitive serial work on CPU

Serial tasks or latency-sensitive operations (e.g., decision-making, control logic) should remain on the CPU

Application Code

Rest of sequential CPU code

Intensive computation

CPU

GPU

Keep data where it used

Minimize memory transfer overhead. Use shared memory on the GPU for frequently accessed data to reduce latency. Use host memory for CPU tasks.

Best practices

Identify tasks that are inherently parallel and offload them to the GPU. Use profiling tools to determine bottlenecks and optimize data movement between CPU and GPU.

- Massive parallelism through thousands of concurrent threads
- ► Hierarchical organization for efficient execution
- ► SIMD architecture for parallel data processing


Thread

Block


Warp/wavefront

Grid


► Traditionally, processors are composed by more than one core (multi-core)




- SISD: Single Instruction Single Data ("classic" iterative and sequential handling)
- Supported by almost every conventional processors



- ▶ **SIMD:** Single Instruction Multiple Data (shared memory parallel model).
- Supported by almost every modern CPU too, harder to write code.
- Algorithms usually require to be redesigned.



- ► SIMT: Single Instruction Multiple Threads
- Large amount of quite simple arithmetical processing units
- Specific processors that require specific programming languages
- Algorithms need to be rethought



- for **i=1..1024**
- ▶ A[i]=...
- end for

▶ The whole 1024 iterations must be executed...

Iteración	1	Iteración	22	Iteración	061	Iteración	002
Iteración		Iteración		Iteración		Iteración	
Iteración	_	Iteración		Iteración		Iteración	
Iteración	_	Iteración		Iteración		Iteración	
Iteración		Iteración		Iteración		Iteración	
Iteración		Iteración		Iteración		Iteración	
Iteración	-	Iteración		Iteración		Iteración	
Iteración		Iteración		Iteración		Iteración	
Iteración		Iteración		Iteración		Iteración	
Iteración	10	Iteración	42	Iteración		Iteración	
Iteración	11	Iteración	43	Iteración	971	Iteración	1003
Iteración	12	Iteración	44	Iteración	972	Iteración	1004
Iteración	13	Iteración	45	Iteración	973	Iteración	1005
Iteración	14	Iteración	46	Iteración	974	Iteración	1006
Iteración	15	Iteración	47	Iteración	975	Iteración	1007
Iteración	16	Iteración	48	Iteración	976	Iteración	
Iteración		Iteración		Iteración		Iteración	
Iteración		Iteración		Iteración		Iteración	
Iteración		Iteración		Iteración		Iteración	
Iteración		Iteración		Iteración		Iteración	
Iteración		Iteración		Iteración		Iteración	
Iteración		Iteración		Iteración		Iteración	
Iteración		Iteración		Iteración		Iteración	
Iteración		Iteración		Iteración		Iteración	
Iteración		Iteración		Iteración		Iteración	
Iteración		Iteración		Iteración		Iteración	
Iteración		Iteración		Iteración		Iteración	
Iteración		Iteración		Iteración		Iteración	
Iteración		Iteración		Iteración		Iteración	
Iteración		Iteración		Iteración		Iteración	
Iteración		Iteración		Iteración		Iteración	
Iteración	32	Iteración	64	Iteración	992	Iteración	1024

- The whole 1024 iterations must be executed...
- ...but they are required to be executed at the same time

Iteración	1	Iteración 3	3	Iteración	961	Iteración 993
Iteración	2	Iteración 3	1	Iteración	962	lteración 994
Iteración	3	Iteración 3	5	Iteración	963	lteración 995
Iteración	4	Iteración 3	5	Iteración	964	lteración 996
Iteración	5	Iteración 3	7	Iteración	965	lteración 997
Iteración	6	Iteración 3	3	Iteración	966	Iteración 998
Iteración	7	Iteración 3	9	Iteración	967	lteración 999
Iteración	8	Iteración 4)	Iteración	968	lteración 1000
Iteración	9	Iteración 4	l	Iteración	969	lteración 1001
Iteración		Iteración 4		Iteración		lteración 1002
Iteración	11	Iteración 4	3	Iteración		lteración 1003
Iteración	12	Iteración 4		Iteración		lteración 1004
Iteración		Iteración 4		Iteración		lteración 1005
Iteración		Iteración 4		Iteración		lteración 1006
Iteración		Iteración 4		Iteración		lteración 1007
Iteración		Iteración 4		Iteración		lteración 1008
Iteración		Iteración 4		Iteración		lteración 1009
Iteración		Iteración 5		Iteración		lteración 1010
Iteración		Iteración 5		Iteración		lteración 1011
Iteración		Iteración 5		Iteración		lteración 1012
Iteración		Iteración 5		Iteración		lteración 1013
Iteración		Iteración 5	-	Iteración		Iteración 1014
Iteración		Iteración 5		Iteración		Iteración 1015
Iteración		Iteración 5		Iteración		lteración 1016
Iteración		Iteración 5		Iteración		Iteración 1017
Iteración		Iteración 5		Iteración		Iteración 1018
Iteración		Iteración 5		Iteración		Iteración 1019
Iteración		Iteración 6		Iteración		Iteración 1020
Iteración		Iteración 6		Iteración		Iteración 1021
Iteración		Iteración 6		Iteración		Iteración 1022
Iteración		Iteración 6		Iteración		Iteración 1023
Iteración	32	Iteración 6	1	Iteración	992	lteración 1024

Conceptually sets of 32 elements are established → warp

Iteración 1	Iteración 33	Iteración	961	Iteración 993
Iteración 2	Iteración 34	Iteración		Iteración 994
Iteración 3	Iteración 35	Iteración		Iteración 995
Iteración 4	Iteración 36	Iteración		Iteración 996
Iteración 5	Iteración 37	Iteración		Iteración 997
Iteración 6	Iteración 38	Iteración	966	Iteración 998
Iteración 7	Iteración 39	Iteración	967	Iteración 999
Iteración 8	Iteración 40	Iteración	968	Iteración 1000
Iteración 9	Iteración 41	Iteración	969	Iteración 1001
Iteración 10	Iteración 42	Iteración	970	Iteración 1002
Iteración 11	Iteración 43	Iteración	971	Iteración 1003
Iteración 12	Iteración 44	Iteración		Iteración 1004
Iteración 13	Iteración 45	Iteración		Iteración 1005
Iteración 14	Iteración 46	Iteración		Iteración 1006
Iteración 15	Iteración 47	Iteración		Iteración 1007
Iteración 16	Iteración 48	Iteración		Iteración 1008
Iteración 17	Iteración 49	Iteración		Iteración 1009
Iteración 18	Iteración 50	Iteración	15-170	Iteración 1010
Iteración 19	Iteración 51	Iteración		Iteración 1011
Iteración 20	Iteración 52	Iteración		Iteración 1012
Iteración 21	Iteración 53	Iteración		Iteración 1013
Iteración 22	Iteración 54	Iteración		Iteración 1014
Iteración 23	Iteración 55	Iteración		Iteración 1015
Iteración 24 Iteración 25	Iteración 56 Iteración 57	lteración lteración		Iteración 1016 Iteración 1017
Iteración 26	Iteración 58	Iteración		Iteración 1017
Iteración 27	Iteración 59	Iteración		Iteración 1019
Iteración 28	Iteración 60	Iteración		Iteración 1019
Iteración 29	Iteración 61	Iteración		Iteración 1021
Iteración 30	Iteración 62	Iteración		Iteración 1021
Iteración 31	Iteración 63	Iteración		Iteración 1023
Iteración 32	Iteración 64	Iteración		Iteración 1024
		ice de l'ori		


▶ Warps are grouped in sets of (let's say) $2 \rightarrow blocks$


```
Iteración 993
Iteración 1
                  Iteración 33
                                                           Iteración 961
                  Iteración 34
Iteración 2
                                                           Iteración 962
                                                                             Iteración 994
Iteración 3
                  Iteración 35
                                                           Iteración 963
                                                                             Iteración 995
Iteración 4
                  Iteración 36
                                                           Iteración 964
                                                                             Iteración 996
Iteración 5
                  Iteración 37
                                                           Iteración 965
                                                                             Iteración 997
                                                           Iteración 966
                                                                             Iteración 998
Iteración 6
                  Iteración 38
                  Iteración 39
Iteración 7
                                                           Iteración 967
                                                                             Iteración 999
Iteración 8
                  Iteración 40
                                                           Iteración 968
                                                                             Iteración 1000
Iteración 9
                  Iteración 41
                                                           Iteración 969
                                                                             Iteración 1001
                  Iteración 42
                                                           Iteración 970
                                                                             Iteración 1002
Iteración 10
Iteración 11
                  Iteración 43
                                                           Iteración 971
                                                                             Iteración 1003
Iteración 12
                  Iteración 44
                                                           Iteración 972
                                                                             Iteración 1004
Iteración 13
                                                           Iteración 973
                  Iteración 45
                                                                             Iteración 1005
Iteración 14
                  Iteración 46
                                                           Iteración 974
                                                                             Iteración 1006
Iteración 15
                  Iteración 47
                                                           Iteración 975
                                                                             Iteración 1007
Iteración 16
                  Iteración 48
                                                           Iteración 976
                                                                             Iteración 1008
Iteración 17
                  Iteración 49
                                                           Iteración 977
                                                                             Iteración 1009
Iteración 18
                  Iteración 50
                                                           Iteración 978
                                                                             Iteración 1010
Iteración 19
                  Iteración 51
                                                           Iteración 979
                                                                             Iteración 1011
Iteración 20
                  Iteración 52
                                                           Iteración 980
                                                                             Iteración 1012
Iteración 21
                  Iteración 53
                                                           Iteración 981
                                                                             Iteración 1013
Iteración 22
                  Iteración 54
                                                           Iteración 982
                                                                             Iteración 1014
                                                           Iteración 983
Iteración 23
                  Iteración 55
                                                                             Iteración 1015
Iteración 24
                  Iteración 56
                                                           Iteración 984
                                                                             Iteración 1016
Iteración 25
                  Iteración 57
                                                           Iteración 985
                                                                             Iteración 1017
Iteración 26
                  Iteración 58
                                                                             Iteración 1018
                                                           Iteración 986
Iteración 27
                  Iteración 59
                                                           Iteración 987
                                                                             Iteración 1019
Iteración 28
                  Iteración 60
                                                           Iteración 988
                                                                             Iteración 1020
Iteración 29
                  Iteración 61
                                                           Iteración 989
                                                                             Iteración 1021
Iteración 30
                  Iteración 62
                                                           Iteración 990
                                                                             Iteración 1022
Iteración 31
                                                                             Iteración 1023
                  Iteración 63
                                                           Iteración 991
Iteración 32
                  Iteración 64
                                                           Iteración 992
                                                                             Iteración 1024
```

lacksquare All the warps are regrouped ightarrow grid


```
Iteración 33
                                                                            Iteración 993
Iteración 1
                                                          Iteración 961
Iteración 2
                  Iteración 34
Iteración 3
                  Iteración 35
                                                                             Iteración 995
Iteración 4
                  Iteración 36
                                                          Iteración 964
Iteración 5
                  Iteración 37
                                                          Iteración 965
Iteración 6
                  Iteración 38
                                                           Iteración 966
                                                                             Iteración 998
Iteración 7
                  Iteración 39
                                                           Iteración 967
                                                                             Iteración 999
Iteración 8
                  Iteración 40
                                                           Iteración 968
                                                                             Iteración 1000
Iteración 9
                  Iteración 41
                                                           Iteración 969
                                                                             Iteración 1001
Iteración 10
                  Iteración 42
                                                           Iteración 970
                                                                             Iteración 1002
Iteración 11
                  Iteración 43
                                                          Iteración 971
                                                                             Iteración 1003
Iteración 12
                  Iteración 44
                                                           Iteración 972
                                                                             Iteración 1004
                                                                             Iteración 1005
Iteración 13
                  Iteración 45
                                                           Iteración 973
Iteración 14
                  Iteración 46
                                                           Iteración 974
Iteración 15
                  Iteración 47
                                                           Iteración 975
Iteración 16
                  Iteración 48
                                                           Iteración 976
Iteración 17
                  Iteración 49
                                                           Iteración 977
                  Iteración 50
                                                           Iteración 978
                                                                             Iteración 1010
Iteración 18
Iteración 19
                  Iteración 51
                                                           Iteración 979
                                                                             Iteración 1012
Iteración 20
                  Iteración 52
                                                           Iteración 980
Iteración 21
                  Iteración 53
                                                           Iteración 981
                                                                             Iteración 1013
Iteración 22
                  Iteración 54
                                                           Iteración 982
                                                                             Iteración 1014
Iteración 23
                  Iteración 55
                                                           Iteración 983
Iteración 24
                  Iteración 56
                                                           Iteración 984
                                                                             Iteración 1016
Iteración 25
                  Iteración 57
                                                           Iteración 985
                                                                             Iteración 1017
Iteración 26
                  Iteración 58
                                                           Iteración 986
                                                                             Iteración 1018
Iteración 27
                  Iteración 59
                                                           Iteración 987
                                                                             Iteración 1019
Iteración 28
                  Iteración 60
                                                           Iteración 988
                                                                             Iteración 1020
                  Iteración 61
                                                          Iteración 989
                                                                             Iteración 1021
Iteración 29
Iteración 30
                  Iteración 62
                                                                             Iteración 1023
Iteración 31
                  Iteración 63
                                                           Iteración 991
Iteración 32
                  Iteración 64
                                                           Iteración 992
                                                                            Iteración 1024
```


► The grid contains all the elements to be processed in the GPU






The block includes all the elements to be processed in a Streaming Multiprocessor (SM/SMx)






Particulary, blocks are executed in sets of 32 elements (warps). First a warp...



...and after the previous one ends, the second warp is executed.



- Massive parallelism through thousands of concurrent threads
- ► Hierarchical organization for efficient execution
- SIMD architecture for parallel data processing

Thread

Smallest unit of execution. Each thread processes a single data element in parallel.

Block

Collection of threads that can share resources and synchronize. Organized in 1D, 2D, or 3D

Warp/wavefront

Group of threads (typically 32) that execute the same instruction simultaneously (SIMD)

Grid

Array of blocks that represents the complete parallel computation structure

Thread

Smallest unit of execution. Each thread processes a single data element in parallel.

Block


Collection of threads that can share resources and synchronize. Organized in 1D, 2D, or 3D

Warp/wavefront

Group of threads (typically 32) that execute the same instruction simultaneously (SIMD)


Grid

Array of blocks that represents the complete parallel computation structure




The GPU memory hierarchy


- Multiple Memory Spaces: local, global, shared, texture, and constant memories.
- ► Local Memory: Private to each thread.
- ► Global Memory: Accessible by all threads but has higher latency.
- Shared Memory: Available to all threads within a block, offers fast access for shared data, reducing access latency compared to global memory.
- Texture and Constant Memories: Read-only and accessible by all threads
- Performance Optimization: Effective use of memory types can enhance application performance and efficiency.



Two specials: unified and pinned memory

- Unified Memory:
 - Shared memory space between CPU and GPU.
 - Simplifies programming by removing explicit memory copies.
 - Useful for irregular memory access patterns.
 - May introduce overhead due to automatic data migration.
- Pinned Memory:
 - ► Host memory locked in physical memory.
 - Enables faster data transfers between CPU and GPU.
 - Supports asynchronous data transfers.
 - ▶ Ideal for frequent and large data transfers.





Memory Type	Access Scope	Latency	Bandwidth	Use Case
Local Memory	Private to each thread	Low	High	Temporary variables for individual threads
Global Memory	Accessible by all threads	High	Moderate	Large datasets shared across threads
Shared Memory	Within a thread block	Low	High	Data shared among threads in the same block
Texture/Constant	Read-only by all threads	Moderate	High	Frequently accessed data with spatial locality
Unified Memory	Shared by CPU and GPU	Moderate	Moderate	Simplifies programming by removing explicit memory copies
Pinned Memory	Host memory (CPU)	Low (transfer)	High (transfer)	Faster data transfers between CPU and GPU

Data Transfer CPU → GPU

Transfer Methods


- Explicit Memory Copy (cudaMemcpy, hipMemcpy, etc)
- Pinned Memory for faster transfers
- Asynchronous transfers with streams
- Unified Memory (automatic management)

Best Practices

- Minimize CPU-GPU transfers
- Batch small transfers together
- Use async transfers to overlap computation
- Consider using Unified Memory for simplicity

Key Performance Considerations

- Memory transfers are often the bottleneck in GPU applications
- Use shared memory for frequently accessed data
- Coalesce global memory accesses when possible
- Balance register usage vs occupancy
- Profile memory access patterns to identify bottlenecks



Standard C Code

C with CUDA extensions

- for i=1..nElements
- ▶ A[i]=...
- end for

Standard C Code C with CUDA extensions _global__ void saxpy(int n, float a, void saxpy(int n, float a, float *x, float *y) float *x, float *y) for (int i = 0; i < n; ++i) int i = blockIdx.x*blockDim.x + threadIdx.x; y[1] = a*x[1] + y[1];1T (1 < n) y[1] = a*x[1] + y[1];int N = 1 << 20; int N = 1 << 20: cudaMemcpy(x, d_x, N, cudaMemcpyHostToDevice); cudaMemcpy(y, d_y, N, cudaMemcpyHostToDevice); // Perform SAXPY on 1M elements // Perform SAXPY on 1M elements saxpy(N, 2.0, x, y); saxpy <<< 4096,256>>> (N, 2.0, x, y);cudaMemcpy(d_y, y, N, cudaMemcpyDeviceToHost);

- ► This is where **thread** appears
 - Each thread can establish its unique identifier within the block
 - Each block can establish its identifier within the grid

```
i = threadIdx.x+(blockIdx.x*blockDim.x)
```

Standard C Code

// Perform SAXPY on 1M elements saxpy(N, 2.0, x, y);

C with CUDA extensions

- ▶ The kernels are executed N times in parallel by N different CUDA threads
- A kernel is defined using the __global__ declaration
- The number of CUDA threads that execute that kernel for a given kernel call is specified using a <-- ... >>> execution configuration syntax.

```
int blockSize = 128;
int gridSize = N / blockSize + 1;
or int gridSize = (N + blockSize - 1) / blockSize;
myKernel <<<gridSize,blockSize>>> (arguments)
```


blockSize should be a round multiple of the warp size! It can be tuned to maximize the "occupancy" of the GPU

Standard C Code

C with CUDA extensions


Performance optimization strategies


- Vectorization
- Memory access optimization
- ► Kernel/subroutine implementation
- ► Thread management and load balancing
- Computation optimization and best practices



Vectorization

- Vectorization refers to the process of organizing computations to take advantage of the SIMD (Single Instruction, Multiple Data) nature of GPU hardware.
- Data Organization
 - ► Structure arrays-of-structures vs <u>structures-of-arrays</u>
 - Align data for coalesced memory access
 - ▶ Pack data for SIMD operations
- Computation patterns
 - ► Loop unrolling for vector operations
 - Vectorization-Friendly Patterns
 - ► Replace sequential dependencies with parallel alternatives
 - Use tiling and blocking for better data locality
 - Minimize divergent execution paths






Vectorization & Race conditions

A 'race condition' arises if two or more threads access the same variables or objects concurrently and at least one does updates.

Example: Suppose t_1 and t_2 simultaneously execute the statement x = x + 1; for some static global x.

- Internally, this involves loading x, adding 1, and storing x.
- If t_1 and t_2 do this concurrently, the statement is executed twice, but x may only be incremented once.
- t_1 and t_2 'race' to do the update.
 - Initial value of x = 0.
 - t_1 reads x (0), adds 1, and stores 1.
 - t_2 reads x (0), adds 1, and stores 1.
 - Final value of x 1 (instead of




Vectorization & Race conditions

Common Race Conditions

- Multiple threads updating shared memory
- Concurrent access to boundary elements
- Reduction operations (sum, max, min)

Prevention Strategies


- Atomic operations for critical sections
- Memory barriers and synchronization
- Thread-local storage for intermediate results



Memory access optimization

Coalesced Memory Access

- Adjacent threads should access adjacent memory locations
- Example: Thread 0 → Address N, Thread 1 → Address N+1
- ► Can improve memory bandwidth utilization by up to 32x



Kernel/subroutine implementation

- Followwed the so-called Embedded Domain Specific Language (eDSL)
- ► Each module has the same CPU subroutine and CUDA kernel
- During compilation, appropriate computing modules are compiled
- Each kernel is programmed once, avoiding duplicated information
- Readability + reproducibility and trustfulness between different architectures
- Eliminates eventual human mistakes usually made when porting the code

```
ACTIVE_GPU: flag to enable GPU compilation
                                                        ACTIVE_OMP: flag to enable CPU compilation
                                                        ncols: number of columns
THREAD_BLOCK: group of threads executed in parallel
                                                       global_dt: time step size
device_vec: array containing all the GPU vectors
                                                       host_vec: array containing all the CPU vectors
H, HU, HV, DEM: integers pointing to the beginning of
                                                       id: temporary integer ranging all the cells
the water depth, x-unit discharge, y-unit-discharge
and elevation vectors respectively
 //kernel/subroutine call
  Kernels::wet_dry<< <(nrows*ncols+THREAD_BLOCK -1)/THREAD_BLOCK, THREAD_BLOCK, 0, streams>> >(nrows*ncols,
    nrows, ncols, global_dt, device_vec[H], device_vec[HU], device_vec[HV], device_vec[DEM]);
  Kernels::wet_dry(nrows*ncols, nrows, ncols, global_dt, host_vec[H], host_vec[HU], host_vec[HV],
#endif
 /kernel/subroutine declaration
  template < typename T>
#ifdef ACTIVE_GPU
  __global__
#endif
  void wet_dry(int size, int nrows, int ncols, T dt, T *h_arr, T *hu_arr, T *hv_arr, T *dem)
    int id = blockIdx.x * blockDim.x + threadIdx.x;
      return;
    #pragma omp parallel for
    for (int id = 0; id < size; id++)
  #endif
#ifdef ACTIVE_OMP
#endif
```

Thread management

Thread Block Optimization

- Optimal block size: Multiple of 32 (warp size)
- Common sizes: 128, 256, or 512 threads per block
- Balance block size with resource usage

Warp Management

- Warp Size: 32 threads execute in lockstep (NVIDIA)
- Avoid warp divergence in conditional statements
- Keep warps fully occupied when possible

Common Pitfalls

- Thread divergence in loops with varying iterations
- Unbalanced workload distribution
- Excessive synchronization points



Performance Tips

- Use <u>occupancy calculator</u> for optimal configuration
- Monitor warp execution efficiency
- Consider dynamic parallelism for irregular workloads

Load balancing

Static Distribution

- Equal-sized blocks for uniform work
- Ideal for regular grid computations
- Example: Basic fluid grid calculations

Dynamic Distribution

- Adaptive work assignment
- Work queues and task pools
- Example: Adaptive mesh refinement

Common Load Imbalance Scenarios

- Boundary Regions
- Different computation requirements at boundaries vs. interior
- Interface Tracking
- Varying computational intensity near interfaces
- Adaptive Time Stepping
- Different regions requiring varied temporal resolution
- Complex Physics Regions
- Areas with additional physical phenomena



Optimization Techniques

- Task merging
- Combine small tasks to reduce overhead
- Work stealing
- Dynamic redistribution of tasks
- Persistent threads
- Maintain active threads for varying workloads

Computation optimization and best practices

- Maximize computations per memory access
- Reduce redundant calculations by precomputing constants
- Overlap independent instructions to maximize throughput
- Avoid dependencies between consecutive instructions
- Use compiler optimizations to schedule instructions efficiently

- Unroll loops to reduce overhead and improve performance
- Minimize loop-carried dependencies
- Use shared memory for intermediate results in iterative computations
- Balance computation and memory access
- Avoid excessive synchronization points
- Profile kernels to identify hotspots







GPU programming foundations and performance optimization

Mario Morales Hernández (mmorales@unizar.es)

March18 2025